

שם המרצה: רויטל מרבל

חיזוי צריכת קנאביס באמצעות אלגוריתמי למידת מכונה



מגישות:

עדי שכטר

אלמוג יוספיאן

דפנה דוידזון

שאלת המחקר

האם ניתן לחזות שימוש בסם קנאביס על בסיס
תכונות אישיות ומאפיינים דמוגרפיים באמצעות
אלגוריתמי למידת מכונה

למה זה חשוב?

זיהוי מוקדם של אוכלוסיות בסיכון למניעת התמכרויות.



שאלת מחקר משנית

האם ניתן לחזות על פי תכונות אישיות ונתונים
דמוגרפיים את סוג הסם שבו משתמשים

למה זה חשוב?

אפיון והשוואה אנחנו בודקים אם יש "תכונה דומיננטית"
שדוחפת אדם לסם מסוים לעומת אחר.
הרחבת המודל מעבר לקנאביס כדי לבחון את הדיוק שלו על
קבוצות חומרים שונות.



מאגר הנתונים

ועיבוד הנתונים

מקור הנתונים

מאגר ה UCI Drug Consumption-
הכולל 1885 משתתפים.

משתנה המטרה

צריכת קנאביס,
אותו הפכנו למשתנה בינארי. לא משתמש 0
משתמש 1

מה נמדד?

שילוב של תכונות אישיות ומאפיינים דמוגרפיים.
משתנים אישיותיים כגון: נויירוטיות, מוחצנות
אימפולסיביות.
ומשתנים דמוגרפיים כגון: השכלה, גיל, מגדר



הסבר על המשתנים



משתנים דמוגרפיים



משתנים אישיותיים

משתנים אישיים >

נוירוטיות-ציון גבוה מעיד על נטייה לחרדה, דאגה, מצבי רוח משתנים ולחץ. ציון נמוך מעיד על יציבות רגשית.

מוחצנות- ציון גבוה מעיד על אדם חברותי אנרגטי, דברן. ציון נמוך מעיד על נטייה למופנמות.

פתיחות לחוויות-ציון גבוה מעיד על בן אדם פתוח, סקרן נכונות ופתיחות להתנסות בדברים חדשים. ציון נמוך מעיד על שמרנות והעדפת המוכר.

נעימות/אמפתיה- ציון גבוה מעיד על אמפתיה, נכונות לשיתוף פעולה ונטייה להסכים עם אחרים בשביל להימנע מקונפליקטים. ציון נמוך מעיד על אדם תחרותי סקפטי ופחות מתחשב.

מצפוניות- ציון גבוה מעיד על סדר, אחראיות תכנון קדימה ושליטה בדחפים. ציון נמוך מעיד על ספונטניות, חוסר סדר.

אימפולסיביות- ציון גבוה מעיד על קושי בדחיית סיכונים רגעיים.

חיפוש ריגושים- ציון גבוה מעיד על נטייה לחיפוש אדרנלין וחוויות עוצמתיות(אחד מהמנבאים החזקים שיש לניבוי שימוש בחומרים פסיכואקטיביים).

משתנים דמוגרפיים





גיל: חלוקה לקבוצות גיל המאפשרת למודל לזהות תקופות חיים המאופיינות סיכון גבוה יותר להתנסות ראשונית או לשימוש קבוע. ניתן לראות את העלייה בצריכה אצל אנשים בשנות ה-20 המוקדמות (18-24)

מגדר: הבחנה בין גברים לנשים לבדיקת קיומם של פערים סטטיסטיים בבחירת סוגי החומרים ובתדירות השימוש. בגרף ניתן לראות צריכה זהה בין גברים לבין נשים.


השכלה: מדרג רמות למידה (מתיכון ועד תארים מתקדמים) המשמש כאינדיקטור לרקע חברתי-כלכלי ולמודעות להשלכות השימוש.

מדינה: משתנה קטגורי המייצג את סביבת המגורים. מאפשר למודל לשקלל גורמי תרבות, חקיקה מקומית וזמינות של קנאביס וסמים אחרים. לדוגמה לפי גרף הנתונים שלנו ניתן לראות שבבריטניה מספרים המשתמשים הוא הרב ביותר.

מוצא: חלוקה לקבוצות מוצא (במידה וקיים במאגר) המשמשת לזיהוי מתאמים תרבותיים וסביבתיים המשפיעים על דפוסי צריכה. בגרף שלנו ניתן לראות שכמות האנשים הלבנים שמתמשים הוא הרב ביותר.



חקירת הנתונים (EDA)



עיבוד הנתונים - שלבי העבודה

שלב 1: טעינה וחקירת הנתונים

טעינת מאגר הנתונים ובדיקת המבנה שלו.

בשלב זה וידאנו שכל הנתונים (מדדי האישיות והנתונים הדמוגרפיים) תקינים, ללא ערכים חסרים ומוכנים לעבודה.

שלב 2: עיבוד והכנת הנתונים

נרמול מספרי: הבאת הנתונים לקנה מידה אחיד לשיפור דיוק המודלים. הנתונים הגיעו כבר מנורמלים.

לכן המרנו משתנים נבחרים לקטגוריאליים כדי להקל על הניתוח והתצוגה בגרפים. ואז החזרנו אותם לנומרים על מנת שנוכל לבנות את המודלים בצורה תקינה. יצרנו מבנה נתונים מסודר המשלב ערכים מספריים לחישוב ותוויות קטגוריות להצגה.

שלב 3: הגדרת מטרת המחקר

הפיכת עמודת ה"קנאביס" למשתנה בינארי (דו-ערכי): "משתמש" (1) מול "לא משתמש" (0). צעד זה קריטי כדי שנוכל לבצע סיווג וחיזוי.

שלב 4: חלוקת הנתונים

פיצול המאגר לשני חלקים: 80% לאימון (הנתונים שעליהם המודל לומד) ו-20% לבדיקה (נתונים חדשים שהמודל לא ראה, עליהם בחנו את רמת הדיוק שלו).

שלב 5: אימון והשוואת מודלים

הרצת 4 אלגוריתמים שונים במקביל: רגרסיה לוגיסטית, KNN, עץ החלטה ויער אקראי (Random Forest). השווינו את התוצאות ביניהם כדי למצוא את המודל המדויק ביותר.

מטרת הסקירה

הצגה של ההתפתחויות המחקריות
האחרונות בתחום, תוך השוואה בין
שיטות, ממצאים ומגמות מחקריות

ממצאי ספרות

אספנו 7 מחקרים מרכזיים משנים 2019 עד 2024

הצדקת מאגר הנתונים: מחקרו של Han משנת 2020 שחווה שימוש בסמים הוכיח כי מאגר ה-UCI הוא המקור המהימן והמדויק ביותר לבניית מודלים חזויים בתחום זה.

הקשר הפסיכולוגי והדמוגרפי: אישיות אינה רק רקע; לפי Jaisawal (2023) ו-Springer (2019), ציוני האישיות הם המנבאים המרכזיים שמאפשרים הגעה לתוצאות מדויקות.

מחקר (Springer 2024) מדגיש כי גיל והשכלה משפיעים משמעותית על דפוסי הצריכה ורמת הסיכון, ולכן שולבו במודל שלנו.

אופטימיזציה ובחירת מודל:

כדי למנוע "רעש" וסטיות, השתמשנו במתודולוגיה של Slam (2022) לנירמול 12 משתנים מתוך ה-Dataset. מחקר (Bouramoul 2023) הראה כי שיטת ה-Ensemble (כמו Random Forest) משפרת את הדיוק ב-5% עד 7% לעומת מודל בודד.

מדדי הצלחה: הסקירה סיפקה לנו את הכלים לבחור במדדי Accuracy ו-Recall כקריטיים להבנת איכות החיזוי בהתנהגות אנושית מורכבת.

ממצאי ספרות

המאמרים מספקים תמיכה מוצקה לשאלת המחקר ולעבודה המתבצעת על ה-UCI Drug Consumption Quantified Dataset.

מגמה ברורה: כלל המאמרים מאוששים תמיכה בנתונים ובדטא , קיימים מאמרים עם מאפיינים דמוגרפיים ואישיותיים, כאלו שחוזים לפי תכונות אישיות וסציו אקונומי.

מודלים מתקדמים כמו ensemble learning מגבירים את הדיוק והאמינות.


האלגוריתמים שנבחרו למחקר

מודל KNN - השכן הקרוב ביותר

איך המודל עובד?

המודל מנבא שימוש בקנאביס על סמך מציאת K
הנבדקים הדומים ביותר לנבדק
(במדדי גיל, אישיות ודמוגרפיה) אם רוב השכנים הדומים
משתמשים. המודל יסווג גם את הנבדק כמשתמש.

Confusion Matrix - KNN



מודל KNN - המשך


ביצועי המודל (על פי התוצאות בשטח):

יכולת איתור מושלמת (Recall): 1.0 (100%) - המודל מצליח לאתר את כלל המשתמשים במדגם ללא יוצא מן הכלל.

דיוק כללי (Accuracy): 0.351 - למרות איתור כל המשתמשים, הדיוק הכללי נמוך מכיוון שהמודל נוטה לסווג נבדקים רבים כמשתמשים (מה שיוצר "אזעקות שווא").

F1-Score ציון

עומד על 0.405, המייצג את האיזון שבין הרגישות הגבוהה לבין הדיוק בחיזוי הקנאבי



מדד ה-F1-Score:

- מדד המשלב בין הדיוק (Precision) לבין הרגישות (Recall).
- בפרויקט שלנו, ה-F1 עוזר לנו למצוא את המודל המאוזן ביותר - זה שמצליח לאתר כמה שיותר משתמשים (Recall) מבלי לייצר יותר מדי "אזעקות שווא" (Precision).


הא שנבחר אצלנו הוא 20 שכנים קרובים ובדקנו מה האופטימלי.

ניצול נתונים ואופטימיזציה:

- רגישות לקנה מידה: אלגוריתם KNN מבוסס על חישובי מרחקים, ולכן הוא רגיש מאוד לקנה המידה של המשתנים.
- חשיבות הנרמול: המודל ניצל היטב את נרמול הנתונים (Scaling) שבוצע, מה שאפשר לו לבצע את חישובי הדמיון בין הנבדקים בצורה תקינה.

מודל עץ החלטה

איך המודל עובד?



מודל עץ החלטה

ביצועי המודל (Target: Cannabis):

דיוק כללי

המודל מציג איזון טוב יחסית בהשוואה למודלים אחרים - 0.673

איזון מדדים

0.614 - המודל מצליח לתפוס מעל 60% (רגישות) Recall

..מהמשתמשים בפועל


דיוק

המודל פחות "שמרני" מהרנדום פורסט מה שמוביל ליותר - 0.359 :

זיהויים אך גם ליותר אזעקות שווא

F1-Score ציון

ציון גבוה המעיד על איזון טוב בין יכולת האיתור לדיוק החיזוי - 0.453



עץ ההחלטה הוא המודל שנתן לנו את התמונה הכי מאוזנת. הוא לא קיצוני לשום צד, ולכן ציון ה-F1 שלו הוא מהגבוהים שקיבלנו


Random Forest

איך המודל עובד?

ככל שהסם נדיר יותר במציאות, למודל קשה יותר ללמוד אותו והוא נוטה פשוט לנחש שכולם 'לא משתמשים'.
בחיזוי קנאביס (שהוא נפוץ יחסית) הביצועים שלו סבירים,
אך עדיין פחות מאוזנים מעץ ההחלטה הבודד.

מודל יוצר "יער" של מאות עצי החלטה אקראיים
המבצעים "הצבעה" על התוצאה הסופית.
(Ensemble)
שיטה זו מעלה משמעותית את יציבות החיזוי


Random Forest



בנינו את המודל על מנת לחזות את שאלת
המחקר המשנית: איך משפיעים הנתונים האישיים
והדמוגרפיים על סוג הסם שבו משתמשים?

חקרנו את המאפיינים האישיים וסינכרנו אותם עם
סוג הסם כך שנוכל לחזות את הסם הספציפי.

ביצועים מקסימליים של הקנאביס - 0.94




Random Forest

ניתוח תוצאות לקנאביס:

- דיוק כללי: 0.761 - זהו הדיוק הגבוה ביותר מבין המודלים שהוצגו
- מדד הדיוק: 0.387 - **המודל הוא ה"מדויק" ביותר**; כשהוא חוזה שימוש, הסיכוי שהוא צודק הוא הגבוה ביותר
- יכולת איתור: 0.145 - המודל סובל מ"שמרנות" יתרה ומפספס חלק גדול מהמשתמשים בפועל
- F1-Score ציון
- ציון נמוך הנובע מחוסר האיזון בין הדיוק הגבוה לרגישות הנמוכה - 0.211
- תובנת "חוסר איזון" והבדלים בין סמים
- **שונויות בין סמים**: קיימת היררכיית חיזוי ברורה. בעוד שבסמים "קשים" ונדירים יותר יכולת השימוש שנבדקה . צונחת (0.2 ומטה), לפי החיזוי השימוש בקנאביס גבוה ביותר
- **מגבלת זיהוי**: למרות הדיוק הכללי הגבוה, המודל מוטה לטובת מחלקת הרוב ("לא משתמש"), מה שמוביל ליכולת
- זיהוי מוגבלת של משתמשים בפועל ככל שהסם נדיר יותר במדגם. מאחר ורוב הנתונים שנמצאים במאגר הינם האנשים שלא משתמשים על מנת שהנתונים לא יוטו לטובתם מספר העצים שבחרנו הוא 100 לתוצאה מיטבית

רגרסיה לוגיסטית

איך המודל עובד?



- המודל הופך את "ציוני האישיות" להסתברות (ערך בין 0 ל-1) באמצעות עקומת הסיגמואיד.
- במקום סיווג "קשיח", המודל מאפשר לקבוע את רמת הסיכון המדויקת של כל נבדק.

ביצועי המודל:

דיוק כללי (Accuracy): 0.503 - למרות דיוק בינוני, המודל מפצה על כך ברגישות יוצאת דופן לאיתור משתמשים.
יכולת איתור (Recall): 0.952 - רמת רגישות גבוהה מאוד; המודל מזהה כמעט את כל המשתמשים בפועל במדגם (מעל 95%).
ציון F1-Score:

0.458 - הציון הגבוה ביותר במחקר עבור קנאביס.

זהו המדד המעיד על האיזון המיטבי שהושג בין זיהוי משתמשים לבין צמצום טעויות.

Precision עומד על 0.302, נמוך בשל 'רגישות יתר' של המודל, המעדיף התראות שווא על פני פספוס משתמשים בסיכון.

רגרסיה לוגיסטית

איזון בין זיהוי לצמצום טעויות:

המודל הגיע לציון F1 הגבוה במחקר (0.458), המייצג שילוב אופטימלי בין איתור משתמשים לדיוק בחיזוי.

• אופטימיזציית סף:

התאמנו את סף המודל (מעבר ל-0.5 המקובל) כדי להתמודד עם חוסר האיזון בנתונים.


כיוון זה הביא את המודל לביצועי שיא והפך את החיזוי לשימושי ומדויק יותר בשטח.

יתרון הפרשנות (הבנת ה"למה"):

המודל מאפשר לזהות את ה"משקל" של כל תכונה:

ניתן לראות אילו מדדי אישיות הם גורמי הסיכון המשמעותיים ביותר.

דוגמה: עלייה במדד ה-Oscore (פתיחות למחשבה) מעלה סטטיסטית את הסבירות לחיזוי שימוש, מה שתואם את ממצאי הספרות.



המודל חושף את המשקל של כל תכונה; ככל שהפס ארוך יותר ימינה, כך התכונה מעלה את הסיכוי לשימוש.

השוואה בין המודלים

הסבר על המדדים שמופיעים בטבלה:

דיוק כללי (Accuracy): אחוז התחזיות הנכונות שהמודל ביצע (גם "משתמש" וגם "לא משתמש") מתוך כלל הנבדקים במדגם.


מדד הדיוק (Precision): בוחן את אמינות התחזית החיובית - מתוך כל האנשים שהמודל סיווג כ"משתמשים", כמה מהם אכן משתמשים בפועל במציאות.

יכולת איתור (Recall): בוחן את אחוז ההצלחה בזיהוי - מתוך כל המשתמשים הקיימים במציאות, כמה מהם המודל הצליח "לתפוס" ולסווג נכון.

ציון F1-Score: מדד משוקלל המייצג את האיזון שבין מדד הדיוק (Precision) לבין יכולת האיתור (Recall). הוא משמש להערכת איכות המודל הכוללת כאשר יש חשיבות לשני המדדים במקביל.

index	Model	Accuracy	Precision	Recall	F1-Score
0	KNN	0.351	0.254	1.0	0.405
1	Decision Tree	0.673	0.359	0.614	0.453
2	Logistic Regression	0.503	0.302	0.952	0.458
3	Random Forest	0.761	0.387	0.145	0.211

השוואה בין המודלים



Random Forest (הדיוק הכללי): השיג את ה-Accuracy הגבוה ביותר (0.761), אך ה-Recall שלו נמוך מאוד (0.145). זהו מודל "שמרני" – הוא צודק כשהוא חוזה שימוש, אך מפספס משתמשים רבים בפועל.

Decision Tree (האיזון הסביר): מציג Accuracy של 0.673 ו-Recall של 0.614. הוא פחות מדויק מה-Random Forest אך מצליח "לתפוס" הרבה יותר משתמשים, מה שהופך אותו למודל מאוזן יותר ליישום מעשי.

Logistic Regression (ה-F1 הגבוה ביותר): מציג את ה-F1-Score הגבוה ביותר בטבלה (0.458) עם Recall מרשים של 0.952. זהו המודל האופטימלי לזיהוי מירבי של משתמשים תוך שמירה על רמת דיוק כללית סבירה.

KNN (קצה הטווח): בעל Recall מושלם (1.0), אך ה-Accuracy שלו הוא הנמוך ביותר (0.351). המודל מסמן כמעט את כל הנבדקים כמשתמשים, מה שיוצר המון "אזעקות שווא" והופך אותו ללא יעיל להפרדה בין קבוצות.




סיכום ותובנות

סיכום, תובנות ומבט לעתיד

- **מורכבות החיזוי:** התוצאות מראות כי תכונות אישיות לבדן אינן חוזות שימוש באופן מושלם, מה שמעיד על השפעה חזקה של גורמים סביבתיים וחברתיים נוספים.
- **עדיפות למודלים מאוזנים:** מבחינת דיוק - הדיוק הגבוה ביותר הוא של Random Forest, ומבחינת רגישות - רגרסיה לוגיסטית בעלת Recall גבוה (זיהוי מרבית המשתמשים) ובמטרות איתור הוא עדיף.
- **הכרעה בין מדדים (Trade-off):**
- המודל המאוזן והרגיש (Logistic Regression): נבחר כמודל המרכזי לאיתור אוכלוסיות בסיכון בזכות ה-Recall הגבוה (0.952) וה-F1-Score הגבוה במחקר (0.458).
- המודל המדויק והשמרני (Random Forest): נבחר כמודל משלים למקרים בהם נדרשת ודאות גבוהה במיוחד בחיזוי, בזכות ה-Accuracy הגבוה ביותר (0.761).
- **שיפור עתידי:** כדי לשפר את הדיוק מבלי לפגוע ברגישות, מומלץ לבצע כיול ודיוק הגדרות המודל ולהוסיף משתנים חיצוניים כמו רקע חברתי-כלכלי וחשיפה סביבתית.
- **הרחבת המחקר:** השלב הבא יהיה מעבר מחיזוי בינארי (כן/לא) לניתוח רב-ערכי של תדירויות שימוש, תוך בחינת מודלים מתקדמים יותר כמו XGBoost.

תודה על ההקשבה!!!

שאלות?



Random Forest

